МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ЛЬВІВСЬКА ПОЛІТЕХНІКА»
Інститут ІКНІ
Кафедра СШІ

ЗВІТ

до лабораторної роботи № 3
з дисципліни: «Інтелектуальний аналіз та візуалізація даних»
на тему: «Діагностика шкал вимірювання»

Виконав: ст. гр. ШІ-33 Левченко Д.К.
Прийняла: Торська Роксана

Львів – 2026

Тема роботи:

Діагностика шкал вимірювання: визначення шкали кожної змінної набору даних і вибір на цій підставі допустимих статистик, мір зв’язку та способів підготовки змінних до моделі.

Мета роботи:

Навчитися визначати шкалу вимірювання кожної змінної набору даних і на цій підставі вирішувати, які статистики, метрики та способи кодування до неї застосовні, а які — ні.

Індивідуальне завдання (варіант 4):

Набір даних — журнал ковідного відділення: 121 пацієнт і 77 ознак. Файл анонімізовано, але дефекти введення збережено без змін. Варіант містить вісім стовпців, пару змінних для оцінки зв’язку та додаткове питання (табл. 1).

Таблиця 1 — Індивідуальне завдання

Параметр	Значення
Набір даних	Ковід_дані_навчальні.xlsx, аркуш «Лист1», 121 × 77
Стовпці варіанта	Телефон, Ускладнення, Перебіг, Виписка, Ліжко днів, Д-дим1, Фібрин2, МНВ2
Пара для міри зв’язку	ступінь КТ × ЛН
Додаткове питання	У чому різниця між шкалою інтервалів і шкалою відношень? Знайдіть у файлі по одному прикладу кожної та поясніть, яка операція допустима для другої, але не для першої.

ЗАВДАННЯ

1. Визначити шкалу вимірювання для восьми змінних свого варіанта та обґрунтувати кожне рішення.
2. Обчислити для кожної змінної тільки ті статистики, які її шкала допускає.
3. Знайти у власних даних щонайменше три числа, які pandas рахує охоче, але які не мають змісту.
4. Обрати коректну міру зв’язку для заданої пари змінних і пояснити, чому інші не підходять.
5. Визначити спосіб підготовки кожної змінної до моделі відповідно до її шкали.
6. Знайти та виправити десять помилок у чужому аналітичному звіті.
7. Заповнити декларацію про використання інструментів штучного інтелекту.

ТЕОРЕТИЧНІ ВІДОМОСТІ

Шкала вимірювання — це властивість самої величини, а не типу даних у Python. Вона визначає, які порівняння між значеннями мають зміст, а отже — які статистики, міри зв'язку та способи кодування до змінної застосовні. Комп'ютер шкали не знає: pandas охоче порахує середнє від номера телефону чи від кодів категорій, тому визначити шкалу має той, хто аналізує дані.

Номінальна шкала дозволяє лише перевірку на рівність (стать, діагноз). Порядкова додає природний порядок, але відстані між рівнями невідомі (ступінь тяжкості). В інтервальній шкалі різниці мають сенс, а нуль умовний (дати, температура за Цельсієм), тож відношення в ній змісту не мають. Шкала відношень має природний нуль, і вираз «удвічі більше» стає змістовним (тривалість, концентрація). Абсолютна шкала має і природний нуль, і природну одиницю (частка, ККД). Окремо виділяють ідентифікатори — значення, які взагалі не є величиною (номер запису, телефон).

Кожна наступна шкала дозволяє все, що попередня, і ще трохи (табл. 2). Так само шкала визначає й підготовку змінної до моделі: номінальні кодують one-hot без порядку, порядкові — цілими кодами із заданим вручну порядком, дати переводять у тривалості, а ідентифікатори в модель не беруть.

Таблиця 2 — Шкали вимірювання, допустимі статистики та підготовка до моделі

Шкала	Ознака	Допустимі статистики	Підготовка до моделі
Номінальна	лише рівність, порядку немає	мода, частоти, χ^2, V Крамера	one-hot кодування
Порядкова	є порядок, відстані невідомі	+ медіана, квантилі, Спірмен	цілі коди із заданим порядком
Інтервальна	різниці мають сенс, нуль умовний	+ середнє, ст. відхилення, різниці	стандартизація; дати → тривалості
Відношень	природний нуль, відношення мають сенс	+ відсотки, коеф. варіації, геом. середнє	нормалізація або стандартизація, логарифм
Абсолютна	природні і нуль, і одиниця	як для шкали відношень	як для шкали відношень
Ідентифікатор	не є величиною	лише кількість і частоти	у модель не беруть

Міру зв’язку визначає поєднання шкал: для двох шкал відношень — кореляція Пірсона, для двох порядкових — рангова кореляція Спірмена, для двох номінальних — χ^2 і коефіцієнт Крамера V, для шкали відношень і бінарної номінальної — точковий бісеріальний коефіцієнт. Пірсон вимірює лінійний зв’язок і вважає відстані між числами справжніми, тому на кодах категорій дає число, яке змінюється разом із довільним вибором кодів.

Помилки аналізу бувають двох типів: статистика, недопустима для шкали (середнє номінальних кодів, коефіцієнт варіації дат), і число, обчислене на непридатних даних — зі змішаними одиницями, текстом у числовому стовпці, цензурованими значеннями чи ознакою, що вже містить відповідь (витік цільової змінної). Перед нормалізацією обов’язково перевіряють варіативність: у сталому стовпці max дорівнює min, і замість помилки виходить мовчазний NaN.

ХІД РОБОТИ

Етап 1. Паспорт змінних

Спершу перевірено, що бачить pandas. Лише «Фібрин2» має числовий тип float64, решта семи стовпців — object, бо в них змішано значення різних типів. У «Телефоні» 97 рядків і 23 числа (номери, які Excel зберіг без нуля на початку), у «Виписці» — дати й два рядки «24.024.2021» та «20.24.2021», у «Ліжко днів» — запис «9(5 у реан)», у «Д-дим1» — записи «4442; 1084» та «480;», а в «МНВ2» — значення 239 і дата 2015-01-01 замість числа. Тому шкалу визначено за змістом величини, а не за типом даних (табл. 3).

Таблиця 3 — Паспорт змінних

Стовпець	Шкала	Обґрунтування
Телефон	ідентифікатор	номер телефону родича разом з іменем: унікальний для кожного пацієнта і не є величиною, його не можна порівнювати чи усереднювати
Ускладнення	номінальна	вільний текст із назвами ускладнень (ГРДС, ТЕЛА, набряк легень): значення можна лише порівняти на рівність, порядку між ними немає
Перебіг	порядкова	рівні «серед важ» < «важкий» < «вкрай важкий» упорядковані за тяжкістю, але відстані між сусідніми рівнями невідомі
Виписка	інтервальна	дата: різниця двох дат (кількість днів) має сенс, а нуль календаря умовний, тому «удвічі пізніша дата» не має змісту
Ліжко днів	відношень	кількість днів у стаціонарі має природний нуль, а відношення мають сенс: 20 днів — удвічі довше за 10
Д-дим1	відношень	концентрація D-димеру в нг/мл: нуль означає відсутність речовини, відношення мають сенс, а одиницю вимірювання обрано умовно
Фібрин2	відношень	концентрація фібриногену в г/л має природний нуль, тому «удвічі більше фібриногену» має фізичний зміст
МНВ2	абсолютна	МНВ — безрозмірне відношення протромбінового часу пацієнта до норми: природні і нуль, і одиниця (1,0 — норма)

Етап 2. Допустимі статистики

Функція допустима_статистика повертає для стовпця лише ті статистики, які дозволяє його шкала. Рівні «Перебігу» впорядковано вручну через pd.Categorical, для дат пораховано медіану, середню дату й стандартне відхилення в днях, а для шкал відношень і абсолютної — ще й коефіцієнт

варіації. Текстові записи в числових стовпцях перетворює функція як_число: вона бере перше число до «;» або «(».

```
ПОРЯДОК = {'Перебіг': ['серед важ', 'важкий', 'вкрай важкий']}



def як_число(v):
    if isinstance(v, (int, float)):
        return v
    return pd.to_numeric(str(v).split(';')[0].split('(')[0].strip(),
errors='coerce')



def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()


    if ш in ('ідентифікатор',):
        return р
    if ш == 'номінальна':
        частоти = з.astype(str).str.strip().value_counts()
        р['мода'] = частоти.index[0][:40] + '…'
        р['частота моди'] = int(частоти.iloc[0])
        return р
    if ш == 'порядкова':
        рівні = pd.Categorical(з.astype(str).str.strip(),
categories=ПОРЯДОК[стовпець], ordered=True)
        коди = pd.Series(рівні.codes)
        р['частоти'] = {к: int(н) for к, н in
pd.Series(рівні).value_counts(sort=False).items()}
        р['мода'] = рівні.categories[коди.mode()[0]]
        р['медіана'] = рівні.categories[int(коди.median())]
        р['Q1–Q3'] = (рівні.categories[int(коди.quantile(0.25,
interpolation='lower'))],
                      рівні.categories[int(коди.quantile(0.75,
interpolation='lower'))])
        return р
    if ш == 'інтервальна':
        дати = pd.to_datetime(з, errors='coerce').dropna()
        р['не дати'] = len(з) - len(дати)
        р['медіана'] = str(дати.median().date())
        р['середнє'] = str(дати.mean().date())
        р['ст. відхилення, днів'] = round(дати.std() / pd.Timedelta(days=1), 1)
        return р
    числа = pd.to_numeric(з.map(як_число), errors='coerce').dropna()
    р['не числа'] = len(з) - len(числа)
    р['мода'] = round(float(числа.mode()[0]), 3)
    р['медіана'] = round(float(числа.median()), 3)
    р['Q1–Q3'] = (round(float(числа.quantile(0.25)), 3),
round(float(числа.quantile(0.75)), 3))
    р['середнє'] = round(float(числа.mean()), 3)
    р['ст. відхилення'] = round(float(числа.std()), 3)
    р['коеф. варіації'] = round(float(числа.std() / числа.mean()), 3)
    return р
```

Таблиця 4 — Обчислені допустимі статистики

Стовпець	Шкала	Статистики
Телефон	ідентифікатор	непорожніх 120, унікальних 120

Стовпець	Шкала	Статистики
Ускладнення	номінальна	непорожніх 61, унікальних 35; мода: Гострий респіраторний дистрес синдром. Г…; частота моди: 14
Перебіг	порядкова	непорожніх 121, унікальних 3; частоти: серед важ — 30, важкий — 90, вкрай важкий — 1; мода: важкий; медіана: важкий; Q1–Q3: важкий … важкий
Виписка	інтервальна	непорожніх 120, унікальних 90; не дати: 2; медіана: 2022-03-15; середнє: 2022-01-29; ст. відхилення, днів: 109.5
Ліжко днів	відношень	непорожніх 120, унікальних 40; не числа: 0; мода: 10.0; медіана: 15.0; Q1–Q3: 10.0 … 22.0; середнє: 17.883; ст. відхилення: 12.937; коеф. варіації: 0.723
Д-дим1	відношень	непорожніх 59, унікальних 48; не числа: 0; мода: 10000.0; медіана: 1581.0; Q1–Q3: 672.99 … 5300.0; середнє: 3529.674; ст. відхилення: 3690.366; коеф. варіації: 1.046
Фібрин2	відношень	непорожніх 101, унікальних 82; не числа: 0; мода: 4.0; медіана: 3.92; Q1–Q3: 2.7 … 5.05; середнє: 4.22; ст. відхилення: 1.885; коеф. варіації: 0.447
МНВ2	абсолютна	непорожніх 76, унікальних 51; не числа: 1; мода: 1.24; медіана: 1.2; Q1–Q3: 1.075 … 1.38; середнє: 4.414; ст. відхилення: 27.456; коеф. варіації: 6.221

«МНВ2» має середнє 4.414 і коефіцієнт варіації 6.221 при медіані 1.2: це наслідок помилки введення 239, а не реального розкиду. Мода «Д-дим1» дорівнює 10000 — це верхня межа аналізатора, а не найтиповіше значення.

Етап 3. Три безглузді числа

df.describe() і pd.to_numeric охоче рахують середнє для будь-чого, схожого на число. У стовпцях варіанта знайдено чотири такі числа (табл. 5).

```
телефони = pd.to_numeric(df['Телефон'], errors='coerce')
перебіг_абетка = df['Перебіг'].astype('category').cat.codes
мнв = pd.to_numeric(df['МНВ2'], errors='coerce')
д_дим = pd.to_numeric(df['Д-дим1'], errors='coerce')
```

Таблиця 5 — Числа, які pandas рахує, але які не мають змісту

Стовпець	Статистика	Значення	Чому безглузде
Телефон	середнє	758798950	середнє телефонних номерів — не номер і не величина; до того ж pandas узяв лише 23 номери, записані числом без нуля на початку
Перебіг	середнє кодів категорій	0.504	cat.codes нумерує рівні за абеткою («важкий» = 0, «вкрай важкий» = 1, «серед важ» = 2), а не за тяжкістю, тож середнє залежить від правопису, а не від стану пацієнтів
МНВ2	середнє	4.41	середнє 4.41 означало б тяжку коагулопатію, але його тягне вгору одне неможливе значення 239 (помилка введення); медіана — 1.20

Стовпець	Статистика	Значення	Чому безглузде
Д-дим1	середнє	3567	11 значень дорівнюють рівно 10000 — це верхня межа аналізатора, справжні значення більші, а записи на кшталт «4442; 1084» pandas мовчки відкинув

Етап 4. Міра зв’язку для пари «ступінь КТ» × «ЛН»

Обидві змінні пари порядкові: ступінь ураження легень на КТ (легкий < середній < важкий < вкрай важкий < критичний) і ступінь легеневої недостатності (I < I-II < II < II-III < III < III-IV). Тому обрано рангову кореляцію Спірмена. Перед обчисленням зведено варіанти правопису ступеня КТ («середній», «сердній», «серед ступ», «серед ступеня» тощо) і задано порядок рівнів вручну. У стовпці ЛН кириличні «І» змішано з латинськими «IV», тому автоматичне сортування рядків ненадійне: кириличну «І» замінено на латинську, а порядок задано словником.

```
ОБРАНА_МІРА = 'рангова кореляція Спірмена'
ЧОМУ_САМЕ_ВОНА = ('обидві змінні порядкові: у ступеня КТ і ступеня ЛН є природний
порядок, але '
                  'відстані між рівнями невідомі, тому порівнюємо лише ранги, а не
самі коди')

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

КТ_РІВНІ = {'легкий': 1, 'легка': 1, 'середній': 2, 'сердній': 2, 'серед ступ': 2,
            'серед ступеня': 2, 'важкий': 3, 'вкрай важкий': 4, 'критичний': 5}
ЛН_РІВНІ = {'I': 1, 'I-II': 2, 'II': 3, 'II-III': 4, 'III': 5, 'III-IV': 6}

кт_рівень = df[A].str.strip().map(КТ_РІВНІ)
лн_рівень = df[B].str.strip().str.replace('I', 'I').map(ЛН_РІВНІ)
assert кт_рівень.notna().sum() == df[A].notna().sum(), 'є нерозпізнаний ступінь КТ'
assert лн_рівень.notna().sum() == df[B].notna().sum(), 'є нерозпізнаний ступінь ЛН'

пара = pd.DataFrame({A: кт_рівень, B: лн_рівень}).dropna()
спірмен = пара[A].rank().corr(пара[B].rank())

print('Пацієнтів з обома значеннями:', len(пара))
print(pd.crosstab(пара[A], пара[B]))
print()
print('Кореляція Спірмена:', round(спірмен, 3))
```

Результат виконання:

```
Пацієнтів з обома значеннями: 42
ЛН          1  2  3  4  5  6
ступінь КТ
1.0         4  1  1  1  0  0
2.0         3  5  4  5  0  1
3.0         0  2  0  3  4  1
4.0         0  0  0  1  3  0
5.0         0  0  1  0  1  1


Кореляція Спірмена: 0.642
```

Кореляція Спірмена 0.642 на 42 пацієнтах означає помірний прямий зв’язок: чим більший ступінь ураження легень на КТ, тим вищий ступінь легеневої недостатності. Нижче показано, що станеться, якщо застосувати Пірсона.

```
є_обидва = df[A].notna() & df[B].notna()
абетка_кт = df[A].astype('category').cat.codes[є_обидва]
абетка_лн = df[B].astype('category').cat.codes[є_обидва]


print('Пірсон на кодах за абеткою:        ', round(абетка_кт.corr(абетка_лн), 3))
print('Пірсон на кодах рівнів 1..5 і 1..6:', round(пара[A].corr(пара[B]), 3))
print('Пірсон, якщо КТ закодувати 1, 4, 9, 16, 25:', round((пара[A] **
2).corr(пара[B]), 3))
print('Спірмен для кодів 1, 4, 9, 16, 25: ', round((пара[A] **
2).rank().corr(пара[B].rank()), 3))
print()
print('Пірсон вимірює лінійний зв’язок і вважає відстані між кодами справжніми. Для
порядкових '
      'шкал ці відстані вигадані: за абеткою «важкий» стоїть перед «легкий», а
інший, так само '
      'законний вибір кодів змінює коефіцієнт. Спірмен залежить лише від порядку,
тому не змінюється.')
```

Результат виконання:

```
Пірсон на кодах за абеткою:         -0.456
Пірсон на кодах рівнів 1..5 і 1..6: 0.6
Пірсон, якщо КТ закодувати 1, 4, 9, 16, 25: 0.547
Спірмен для кодів 1, 4, 9, 16, 25:  0.642


Пірсон вимірює лінійний зв’язок і вважає відстані між кодами справжніми. Для
порядкових шкал ці відстані вигадані: за абеткою «важкий» стоїть перед «легкий», а
інший, так само законний вибір кодів змінює коефіцієнт. Спірмен залежить лише від
порядку, тому не змінюється.
```

Пірсон на абеткових кодах дав навіть інший знак, бо за абеткою «важкий» стоїть перед «легкий». Для кодів 1…5 і кодів 1, 4, 9, 16, 25 він дав різні значення, хоча порядок рівнів однаковий. Спірмен в обох випадках однаковий, бо залежить лише від порядку, тому для порядкових шкал інтерпретувати можна тільки його.

Етап 5. Підготовка змінних до моделі

Таблиця 6 — Спосіб підготовки кожного стовпця

Стовпець	Шкала	Як готуємо
Телефон	ідентифікатор	ідентифікатор — у модель не беремо, стовпець видаляємо
Ускладнення	номінальна	номінальна — розбиваємо текст на окремі ускладнення й робимо 0/1-ознаку для кожного, без порядку
Перебіг	порядкова	порядкова — цілі коди із заданим вручну порядком: серед важ = 0, важкий = 1, вкрай важкий = 2
Виписка	інтервальна	інтервальна — переходимо до тривалості в днях від поступлення, потім стандартизуємо
Ліжко днів	відношень	відношень — виймаємо число з тексту, логарифмуємо через довгий правий хвіст і стандартизуємо
Д-дим1	відношень	відношень — виймаємо число, позначаємо цензуровані 10000, логарифмуємо й стандартизуємо
Фібрин2	відношень	відношень — нормалізація min-max після перевірки, що max не дорівнює min
МНВ2	абсолютна	абсолютна — прибираємо неможливі значення (дата Excel, 239) і нормалізуємо min-max

Підготовку виконано для чотирьох стовпців різних шкал: порядкового «Перебігу» (цілі коди із заданим порядком), номінальних «Ускладнень» (окремі 0/1-ознаки для ГРДС, ТЕЛА, набряку легень і шоку), інтервальної «Виписки» (тривалість у днях від поступлення, потім стандартизація) та «Фібрину2» зі шкалою відношень (min-max нормалізація).

```
перебіг_код = df['Перебіг'].str.strip().map({'серед важ': 0, 'важкий': 1, 'вкрай
важкий': 2})


УСКЛАДНЕННЯ = {'ГРДС': 'ГРДС|дистрес', 'ТЕЛА': 'ТЕЛА', 'набряк легень': 'набряк
легень', 'шок': 'шок'}
ускладнення_01 = pd.DataFrame({н: df['Ускладнення'].fillna('').str.contains(в,
case=False)
                               for н, в in УСКЛАДНЕННЯ.items()}).astype(int)


тривалість = (pd.to_datetime(df['Виписка'], errors='coerce')
              - pd.to_datetime(df['Поступлення'], errors='coerce')).dt.days
тривалість_z = (тривалість - тривалість.mean()) / тривалість.std()



def нормалізувати(x):
    if x.max() == x.min():
        raise ValueError('сталий стовпець: max дорівнює min, знаменник нульовий')
    return (x - x.min()) / (x.max() - x.min())



фібрин_01 = нормалізувати(df['Фібрин2'])


print('Перебіг (порядкова), коди:',
перебіг_код.value_counts().sort_index().to_dict())
print('Ускладнення (номінальна), скільки одиниць:', ускладнення_01.sum().to_dict())
print('Виписка (інтервальна) → тривалість: середнє', round(тривалість.mean(), 1),
'дня;',
      f'після стандартизації середнє {abs(тривалість_z.mean()):.3f} і std
{тривалість_z.std():.3f}')
print('Фібрин2 (відношень) після нормалізації: min', фібрин_01.min(), '| max',
фібрин_01.max())
```

Результат виконання:

```
Перебіг (порядкова), коди: {0: 30, 1: 90, 2: 1}
Ускладнення (номінальна), скільки одиниць: {'ГРДС': 44, 'ТЕЛА': 13, 'набряк легень':
17, 'шок': 28}
Виписка (інтервальна) → тривалість: середнє 18.9 дня; після стандартизації середнє
0.000 і std 1.000
Фібрин2 (відношень) після нормалізації: min 0.0 | max 1.0
```

Функція нормалізувати перед діленням перевіряє, що max не дорівнює min: для сталого стовпця вона зупиняється з помилкою, а не повертає мовчазний NaN. Перевірка варіативності восьми стовпців варіанта сталих стовпців не виявила.

Етап 6. Виправлення чужого аналізу

Звіт «ЛР3_помилковий_аналіз.ipynb» виконується без помилок, усі числа в ньому арифметично правильні, але в кожному з десяти розділів є хибне місце: або статистика, недопустима для шкали, або число, обчислене на непридатних даних (табл. 7).

Таблиця 7 — Помилки чужого звіту та їх виправлення

Розділ	Що не так	Чому число неправильне	Як правильно
1	середнє від кодів номінальної ознаки «помер/жив» (1 = помер, 2 = вижив)	коди 1 і 2 — лише мітки; 1.50 означає тільки, що померлих і живих майже порівну, а не стан «посередині між смертю й одужанням»	частки та мода: летальність = (df["помер/жив"] == 1).mean() = 50.4 %
2	частоти номінальної ознаки пораховано на неочищених мітках	«ж» і «жін», «ч» і «чол» — та сама стать, записана по-різному; чотири «статі» — дефект введення, а не результат	звести мітки до першої літери після strip(): ж — 75, ч — 46
3	порядкову шкалу відсортовано за абеткою, коди взято з алфавітного порядку, варіанти правопису не об’єднано	порядок «важкий … середній» абетковий, а середнє кодів 5.9 → «легкий» не має змісту: для порядкової шкали середнє недопустиме	звести правопис до 5 рівнів, задати порядок вручну (легкий < середній < важкий < вкрай важкий < критичний) і взяти медіану — «середній»
4	pd.to_numeric(errors="coerce") мовчки викинув 16 значень, записаних текстом («70-80%», «до 17%»), і порожній рядок	середнє 39.6 % пораховано лише на 27 записах-частках; відкинуті текстові значення в середньому більші (47 %), тож обсяг ураження занижено	розібрати діапазони (середина інтервалу, «до 17%» → 17 %) і перевести все в частки: середнє 42.5 %, медіана 35 %
5	у «spO2 без дот» є значення 0.9 — частка замість відсотків, тобто дані в різних одиницях	середнє 82.05 занижене через 0.9, а висновок про «більшість пацієнтів» із середнього не випливає: про більшість говорить частка, а не середнє	виправити 0.9 → 90 і звітувати медіану 84 % та частку пацієнтів із SpO_2 < 90 % — 74.4 %
6	коефіцієнт варіації для дат — інтервальної шкали з умовним нулем	CV ділить на середнє «днів від 1970 року»; від нуля Excel (1899) ті самі дати дають 0.254 %, тож 0.595 % — артефакт вибору початку відліку	для інтервальної шкали — стандартне відхилення чи розмах у днях: std 113 днів, період 25.02.2021 – 03.06.2022
7	кореляцію Пірсона застосовано до двох номінальних ознак (стать × результат), закодованих 0/1	0.177 не «близько до нуля»: χ^2 = 3.78, майже критичне 3.84, а жінки помирали частіше (57 % проти 39 %); висновок «зв’язку немає» з цього числа не випливає	таблиця спряженості, χ^2 і коефіцієнт Крамера V = 0.177 — слабкий зв’язок на межі значущості
8	min-max нормалізацію застосовано до всіх 40 числових стовпців без перевірки шкали й варіативності	серед них код «помер/жив» (номінальна) і ФЕРИТ2 з одним значенням (max = min), де ділення на нуль дало мовчазні NaN; «усі приведено до [0, 1]» — неправда	нормалізувати лише стовпці шкал відношень та інтервальних, виключити коди й ідентифікатори та перевірити max ≠ min

Розділ	Що не так	Чому число неправильне	Як правильно
9	df.dropna() без параметрів видаляє рядок, якщо пропуск є хоч в одному з 77 стовпців	пропуск є в кожному рядку (11 стовпців заповнені менш ніж наполовину), тому лишилося 0 рядків — «повністю заповнений набір» порожній	dropna(subset=[потрібні стовпці]) або спершу прибрати майже порожні стовпці, а решту пропусків заповнити
10	«Дата розтину» є лише в померлих — це витік цільової змінної; NaT перетворено на int64 як $-9.2\cdot10^{18}$	r = 1.00 означає лише «дата є ↔ пацієнт помер»: розтин роблять після смерті, тож для прогнозу ця ознака недоступна	виключити ознаки, що з'являються після результату, і рахувати точковий бісеріальний коефіцієнт лише для ознак, відомих при поступленні

Три помилки (розділи 1, 3 і 7) виправлено в коді поруч із неправильним обчисленням.

```
помер = df['помер/жив'] == 1
print('Розділ 1')
print('   неправильно: середнє кодів =', round(df['помер/жив'].mean(), 2))
print('   правильно:   летальність =', f'{помер.mean():.1%}')
print()


абетка = df['ступінь КТ'].value_counts().sort_index()
коди_абетки = {назва: і for і, назва in enumerate(абетка.index)}
НАЗВИ_КТ = {1: 'легкий', 2: 'середній', 3: 'важкий', 4: 'вкрай важкий', 5:
'критичний'}
print('Розділ 3')
print('   неправильно: середнє абеткових кодів =', round(df['ступінь
КТ'].map(коди_абетки).mean(), 2))
print('   правильно:   медіана впорядкованих рівнів =',
НАЗВИ_КТ[int(кт_рівень.median())])
print()


стать = df['Стать'].astype(str).str.strip().str[0]
таблиця = pd.crosstab(стать, помер)
O = таблиця.to_numpy(dtype=float)
E = O.sum(axis=1, keepdims=True) * O.sum(axis=0, keepdims=True) / O.sum()
xi2 = ((O - E) ** 2 / E).sum()
крамер = np.sqrt(xi2 / (O.sum() * (min(O.shape) - 1)))
print('Розділ 7')
print('   неправильно: Пірсон =', round(стать.map({'ч': 0, 'ж':
1}).corr(помер.astype(int)), 3),
      '→ «зв'язку немає»')
print('   правильно:   χ² =', round(xi2, 2), '(критичне 3.84 при α = 0.05) | V
Крамера =', round(крамер, 3))
print(таблиця)
```

Результат виконання:

```
Розділ 1
   неправильно: середнє кодів = 1.5
   правильно:   летальність = 50.4%


Розділ 3
   неправильно: середнє абеткових кодів = 5.9
   правильно:   медіана впорядкованих рівнів = середній


Розділ 7
   неправильно: Пірсон = 0.177 → «зв'язку немає»
   правильно:   χ² = 3.78 (критичне 3.84 при α = 0.05) | V Крамера = 0.177
помер/жив  False  True
Стать
ж             32     43
ч             28     18
```

Етап 7. Висновки та індивідуальне питання

Висновки щодо стовпців варіанта:

1. «Ускладнення» заповнено в 61 записі з 121, і всі ці пацієнти померли (61 з 61); у живих поле порожнє, тож це запис про причину смерті, а не ознака при поступленні, і в моделі летальності він дав би витік цільової змінної.

2. «МНВ2» без очищення дає середнє 4.41 через неможливе значення 239 і дату Excel замість числа, тоді як медіана 1.20 — для цього стовпця треба звітувати медіану.

3. «Д-дим1»: 11 з 57 числових значень дорівнюють рівно 10000 — це верхня межа аналізатора, тож середнє 3567 занижене, і доречніше брати медіану 1581.

Додаткове питання: У чому різниця між шкалою інтервалів і шкалою відношень? Знайдіть у файлі по одному прикладу кожної та поясніть, яка операція допустима для другої, але не для першої.

В інтервальній шкалі нуль умовний, тому мають сенс лише різниці, а у шкалі відношень нуль природний, тому мають сенс і відношення. Приклад інтервальної шкали — дата «Поступлення»: між 01.09.2021 і 02.04.2022 минуло 213 днів за будь-якого календаря, а «відношення дат» залежить від початку відліку: 1.0113 від 1970 року і 1.0048 від нуля Excel, тож воно нічого не означає. Приклад шкали відношень — «Ліжко днів»: 0 днів означає відсутність перебування, а 20 днів справді вдвічі довше за 10. Операція, допустима для

шкали відношень і недопустима для інтервальної, — ділення: відношення, відсотки, коефіцієнт варіації (0.72 для ліжко-днів) і геометричне середнє.

Етап 8. Декларація про використання інструментів ШІ

Етап 8 зошита містить декларацію: для кожного етапу обрано одне з п’яти формулювань («ні», «синтаксис», «код, перевірено», «текст, перероблено», «текст, як є»), описано, що саме перевірено, і підтверджено, що кожен рядок коду можна пояснити й змінити на захисті. Без заповненої декларації фінальна самоперевірка зошита не проходить.

ВИСНОВКИ

У роботі для восьми стовпців варіанта 4 визначено шкали вимірювання: «Телефон» — ідентифікатор, «Ускладнення» — номінальна, «Перебіг» — порядкова, «Виписка» — інтервальна, «Ліжко днів», «Д-дим1» і «Фібрин2» — шкала відношень, «МНВ2» — абсолютна. Тип даних pandas виявився ненадійною підказкою: сім із восьми стовпців мають тип object через змішані значення, а єдиний числовий тип нічого не каже про шкалу.

Для кожного стовпця обчислено лише допустимі статистики й знайдено чотири безглузді числа: середнє телефонних номерів, середнє абеткових кодів «Перебігу», середнє «МНВ2» = 4.41, яке тягне вгору помилка введення 239 (медіана 1.20), і середнє «Д-дим1», спотворене цензуруванням на рівні 10000. Окремо встановлено, що «Ускладнення» заповнено лише для померлих пацієнтів, тож у моделі летальності ця ознака дала б витік цільової змінної.

Для пари «ступінь КТ» × «ЛН» обрано рангову кореляцію Спірмена, бо обидві змінні порядкові. Після зведення правопису й ручного впорядкування рівнів вона становить 0.642, тобто зв’язок помірний і прямий. Кореляція Пірсона на тих самих даних залежить від довільного вибору кодів, тому її не можна інтерпретувати.

У чужому аналітичному звіті знайдено й пояснено десять помилок — від середнього номінальних кодів і коефіцієнта варіації дат до df.dropna(), що

залишає нуль рядків, і витоку цільової змінної через дату розтину; три з них виправлено в коді. Головний висновок роботи: перш ніж рахувати будь-яку статистику, треба визначити шкалу величини й перевірити, чи придатні до цього дані.